第一次数据探索——Python 探索性数据分析课后作业

A 异常值检测｜B 真实钻石价格数据 EDA｜C Titanic 探索｜D 电商数据质量

数据获取与运行日期：2026-10-08。全部结果来自随附 Python 程序的实际执行；本报告未训练预测模型。

作业范围与运行环境

使用 Python 3.12，主要依赖 NumPy、Pandas、Matplotlib 与 Seaborn，Word 由 python-docx 生成。数据、中文字体、代码、统计表与图表均随项目保存，运行不依赖联网。源代码采用固定随机种子和明确工作路径，CSV 采用 UTF-8 BOM 编码以便 Excel 打开。

A 题 1 张图，B 题 4 张图，C 题 7 张图，共 12 张。报告表格保留适当小数位；完整精度以 CSV 和 JSON 文件为准。页面中的“—”表示缺失或不适用，不能解释为 0。

本报告依次包含题目要求、方法、关键代码、运行结果与解释；完整 Python 程序另附，便于检查与复现。

A 基础题：异常值检测

A1 题目要求与方法

生成 300 个正态值与 5 个人工随机异常，随机打乱后用箱线图和 IQR 规则筛查，返回行索引，并用已知真值评估检出情况。约定 N(100,15)中的 15 为标准差 σ，方差为 225；部分教材以第二参数表示方差，若按该记法标准差应为√15，本实验不采用该口径。

随机数生成器使用 default_rng(2026)。正常值不截断、不换种子；两个低异常来自[10,30)，三个高异常来自[175,205)。先记录原始行索引 0—304，再用同一生成器随机排列，重建当前行索引。真实异常的原始索引为 300—304，但当前位置已分散。

Q1 和 Q3 采用 Pandas 默认线性分位数；IQR=Q3−Q1。严格小于 Q1−1.5IQR 或大于 Q3+1.5IQR 者为异常候选。箱线图须线延伸到界限内最远的实际观测，并非直接延伸到理论边界。检测过程仅用数值，真值标签只参与评估。

A2 关键代码

```
rng = np.random.default_rng(2026)
# 本题约定 N(100,15) 的第二个参数为标准差，而不是方差。
normal = rng.normal(loc=100, scale=15, size=300)
injected = np.concatenate([rng.uniform(10, 30, 2), rng.uniform(175, 205, 3)])
data = pd.DataFrame({'原始行索引': np.arange(305),
                     '数值': np.concatenate([normal, injected]),
                     '真实异常': [False] * 300 + [True] * 5})
# 保存打乱前原始索引，并另设从零开始的当前行索引，避免两个口径混淆。
data = data.iloc[rng.permutation(len(data))].reset_index(drop=True)
data.index.name = '当前行索引'
q1, q3 = data['数值'].quantile([0.25, 0.75])
iqr = q3 - q1
lower, upper = q1 - 1.5 * iqr, q3 + 1.5 * iqr
data['IQR 判为异常'] = (data['数值'] < lower) | (data['数值'] > upper)
```

A3 实际结果

表 1 IQR 阈值

统计量	数值
Q1	90.039
Q3	111.472
IQR	21.433
下界	57.890
上界	143.621

检测到的当前行索引（从 0 开始）：34、72、123、157、180、215、223、252、269。

真实注入异常的当前行索引：34、157、223、252、269。下表中的原始行索引用于追溯打乱前的位置。

表 2 全部异常候选及真值对照

当前行索引	原始行索引	数值	真实异常	IQR 判为异常	检测分类
34	301	11.950	True	True	真正例
72	297	144.413	False	True	假正例
123	49	147.264	False	True	假正例
157	303	200.245	True	True	真正例
180	188	43.789	False	True	假正例
215	161	143.771	False	True	假正例
223	304	199.801	True	True	真正例
252	302	177.561	True	True	真正例
269	300	20.516	True	True	真正例

表 3 检测混淆矩阵

字段/分组	判为异常	判为正常
真实异常	5	0
真实正常	4	296

真正例 5、假正例 4、漏检 0、真负例 296。召回率 100.0%，精确率 55.6%：全部 5 个人工异常均检出，但并非只标记了 5 条。

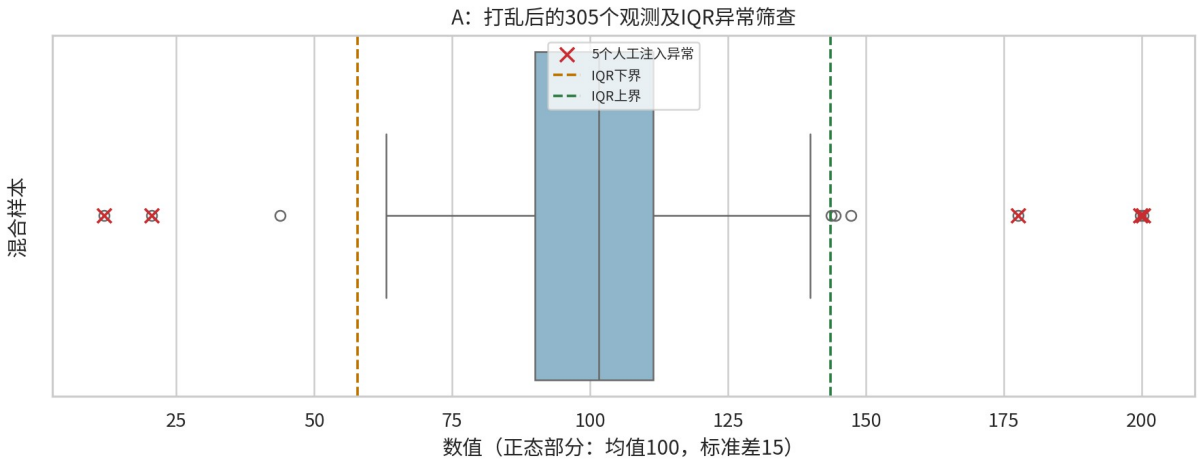


图 1 混合数据箱线图

红色叉号为已知的 5 个人工异常，虚线是理论 IQR 边界。4 个正常生成的尾部观测也超出界限，因此被计为相对于人工标签的假正例；它们不是自动认定的数据错误。

A4 分析结论与局限

IQR 利用中间 50%数据构造较稳健的筛查范围。自然尾部、偏态或混合总体可能导致误检；异常落在界限内、样本量小或异常群体扩大 IQR 时可能漏检。本次异常刻意放在远离中心的区域，因此成功检出不能保证其他场景也达到 100%召回。

B 数据分析题：真实钻石价格数据 EDA

B1 题目要求、数据来源与基本信息

完成形状与基本信息、缺失处理、异常检测、描述统计、Pearson 热力图、帕累托图及约 200 字结论七项要求。选择 ggplot2 经典 diamonds 真实商品价格数据，由 seaborn-data 公开镜像提供。UCI Online Retail 官方下载在当前环境被代理返回 403，因此使用可访问且可追溯的商品数据。

数据名称：diamonds；原始形状为 53,940 行、10 列。它是钻石价格和属性的横截面，没有成交数量、日期或订单编号，不能把价格之和解释成销售收入。

原项目：https://ggplot2.tidyverse.org/reference/diamonds.html

CSV 获取地址：https://raw.githubusercontent.com/mwaskom/seaborn-data/master/diamonds.csv

字段含义：carat 为重量（克拉），cut 为切工，color 为颜色等级（D 至 J），clarity 为净度；depth 为总深度百分比，table 为台面宽度占最大宽度的百分比；price 为美元价格，x、y、z 分别为长、宽、深（毫米）。

表 4 字段类型与非空数量

字段	类型	非空数
carat	float64	53940
cut	object	53940
color	object	53940
clarity	object	53940
depth	float64	53940
table	float64	53940
price	int64	53940
x	float64	53940
y	float64	53940
z	float64	53940

表 5 前五行（转置显示，保留原始字段值）

index	第 1 行	第 2 行	第 3 行	第 4 行	第 5 行
carat	0.230	0.210	0.230	0.290	0.310
cut	Ideal	Premium	Good	Premium	Good
color	E	E	E	I	J
clarity	SI2	SI1	VS1	VS2	SI2
depth	61.500	59.800	56.900	62.400	63.300
table	55	61	65	58	58
price	326	326	327	334	335
x	3.950	3.890	4.050	4.200	4.340

index	第 1 行	第 2 行	第 3 行	第 4 行	第 5 行
y	3.980	3.840	4.070	4.230	4.350
z	2.430	2.310	2.310	2.630	2.750

B2 缺失值、重复值与处理

原始表各字段无缺失，但有 20 条记录含不可能的零物理尺寸：x 有 8 个、y 有 7 个、z 有 20 个，字段间存在重叠，不能相加当作记录数。零尺寸改记缺失；保留整条记录和其他有效属性，不使用均值填补。描述统计逐列使用有效值，相关分析统一采用 53,920 个完整案例。

raw.duplicated()识别出 146 条与此前记录完全相同的候选，即不计每组首次出现的额外记录数。由于没有唯一钻石 ID，相同属性也可能代表不同商品，不直接删除。清洗表额外标记所有属于重复组的记录，因此该标记总数与“额外重复行数”口径不同。

表 6 处理前后缺失情况

字段/分组	原始缺失数	原始缺失率%	处理后缺失数	处理后缺失率%
carat	0	0	0	0
cut	0	0	0	0
color	0	0	0	0
clarity	0	0	0	0
depth	0	0	0	0
table	0	0	0	0
price	0	0	0	0
x	0	0	8	0.015
y	0	0	7	0.013
z	0	0	20	0.037

B3 IQR 异常检测与描述性统计

对 7 个数值字段分别进行 1.5IQR 筛查并保存行级候选。高价和大克拉可能是真实商品；异常尺寸需要回查测量单位与来源。除物理上无效的非正尺寸置缺失外，不依据 IQR 自动删除或截尾。缺失值本身不被 IQR 判为异常，而由缺失统计单独记录。

表 7 各字段 IQR 异常候选

字段	Q1	Q3	IQR	下界	上界	异常候选数	有效样本数
carat	0.400	1.040	0.640	-0.560	2	1889	53940
depth	61	62.500	1.500	58.750	64.750	2545	53940
table	56	59	3	51.500	63.500	605	53940
price	950	5324.250	4374.250	-5611.375	11885.625	3540	53940
x	4.710	6.540	1.830	1.965	9.285	24	53932
y	4.720	6.540	1.820	1.990	9.270	22	53933
z	2.910	4.040	1.130	1.215	5.735	29	53920

至少一个字段超出 IQR 界限的记录共有 6,406 条，其中价格候选 3,540 条。不同字段候选可能重叠，不能直接相加。

表 8 描述统计：有效数、均值、中位数、样本标准差及极值

index	count	mean	median	std	min	max
carat	53940	0.798	0.700	0.474	0.200	5.010
depth	53940	61.749	61.800	1.433	43	79
table	53940	57.457	57	2.234	43	95
price	53940	3932.800	2401	3989.440	326	18823
x	53932	5.732	5.700	1.120	3.730	10.740
y	53933	5.735	5.710	1.140	3.680	58.900
z	53920	3.540	3.530	0.703	1.070	31.800

表 9 四分位数与偏度

index	25%	50%	75%	skew
carat	0.400	0.700	1.040	1.117
depth	61	61.800	62.500	-0.082
table	56	57	59	0.797
price	950	2401	5324.250	1.618
x	4.710	5.700	6.540	0.398
y	4.720	5.710	6.540	2.461
z	2.910	3.530	4.040	1.585

B4 关键代码

```
for col in numeric:
    q1, q3 = clean[col].quantile([.25, .75])
    iqr = q3 - q1
    low, high = q1 - 1.5 * iqr, q3 + 1.5 * iqr
    flag = (clean[col] < low) | (clean[col] > high)
    flags[col + '_IQR 候选'] = flag
    iqr_rows.append({'字段': col, 'Q1': q1, 'Q3': q3, 'IQR': iqr, '下界': low, '上界': high,
                     '异常候选数': int(flag.sum()), '有效样本数': int(clean[col].notna().sum())})
保存表(pd.DataFrame(iqr_rows), ROOT / 'IQR 异常统计.csv', index=False)


invalid_counts = {}
# 钻石物理尺寸应为正数，零尺寸不能解释为真实尺寸；记为缺失，不编造填充值。
for col in ['carat', 'depth', 'table', 'price', 'x', 'y', 'z']:
    invalid = clean[col] <= 0
    invalid_counts[col] = int(invalid.sum())
    clean.loc[invalid, col] = np.nan
missing = pd.DataFrame({'原始缺失数': raw.isna().sum(), '原始缺失率%': raw.isna().mean() * 100,
                        '处理后缺失数': clean[raw.columns].isna().sum(),
                        '处理后缺失率%': clean[raw.columns].isna().mean() * 100})
保存表(missing, ROOT / '缺失值统计.csv')
iqr_rows = []
flags = pd.DataFrame(index=clean.index)
for col in numeric:
    q1, q3 = clean[col].quantile([.25, .75])
    iqr = q3 - q1
    low, high = q1 - 1.5 * iqr, q3 + 1.5 * iqr
```

```
    flag = (clean[col] < low) | (clean[col] > high)
    flags[col + '_IQR 候选'] = flag
    iqr_rows.append({'字段': col, 'Q1': q1, 'Q3': q3, 'IQR': iqr, '下界': low, '上界': high,
                     '异常候选数': int(flag.sum()), '有效样本数': int(clean[col].notna().sum())})
保存表(pd.DataFrame(iqr_rows), ROOT / 'IQR 异常统计.csv', index=False)
保存表(pd.concat([raw, flags], axis=1).loc[flags.any(axis=1)], ROOT / '异常候选记录.csv')
clean['任一 IQR 异常候选'] = flags.any(axis=1)
保存表(clean, ROOT / '清洗后数据.csv', index=False)
desc = clean[numeric].describe().T
desc['median'] = clean[numeric].median()
desc['skew'] = clean[numeric].skew()
保存表(desc, ROOT / '描述性统计.csv')
# 所有相关系数使用同一组完整案例，避免每个格子样本量不同。
complete = clean[numeric].dropna()
corr = complete.corr(method='pearson')
保存表(corr, ROOT / 'Pearson 相关系数.csv')
labels = ['重量/克拉', '总深度/%', '台面宽度/%', '价格/美元', '长/mm', '宽/mm', '深/mm']
plt.figure(figsize=(9, 7))
sns.heatmap(corr, annot=True, fmt='.2f', cmap='RdBu_r', vmin=-1, vmax=1,
            square=True, xticklabels=labels, yticklabels=labels)
plt.title(f'B：钻石数值属性 Pearson 相关（完整案例 n={len(complete):,}）')
保存图(ROOT / '相关系数热力图.png')
# 没有交易数量，采用切工类别的记录数，明确不能称为销售额或市场份额。
counts = clean['cut'].value_counts().sort_values(ascending=False)
pareto = pd.DataFrame({'记录数': counts, '占比%': counts / counts.sum() * 100,
                       '累计占比%': counts.cumsum() / counts.sum() * 100})
保存表(pareto, ROOT / '切工帕累托统计.csv')
```

B5 相关分析与图表

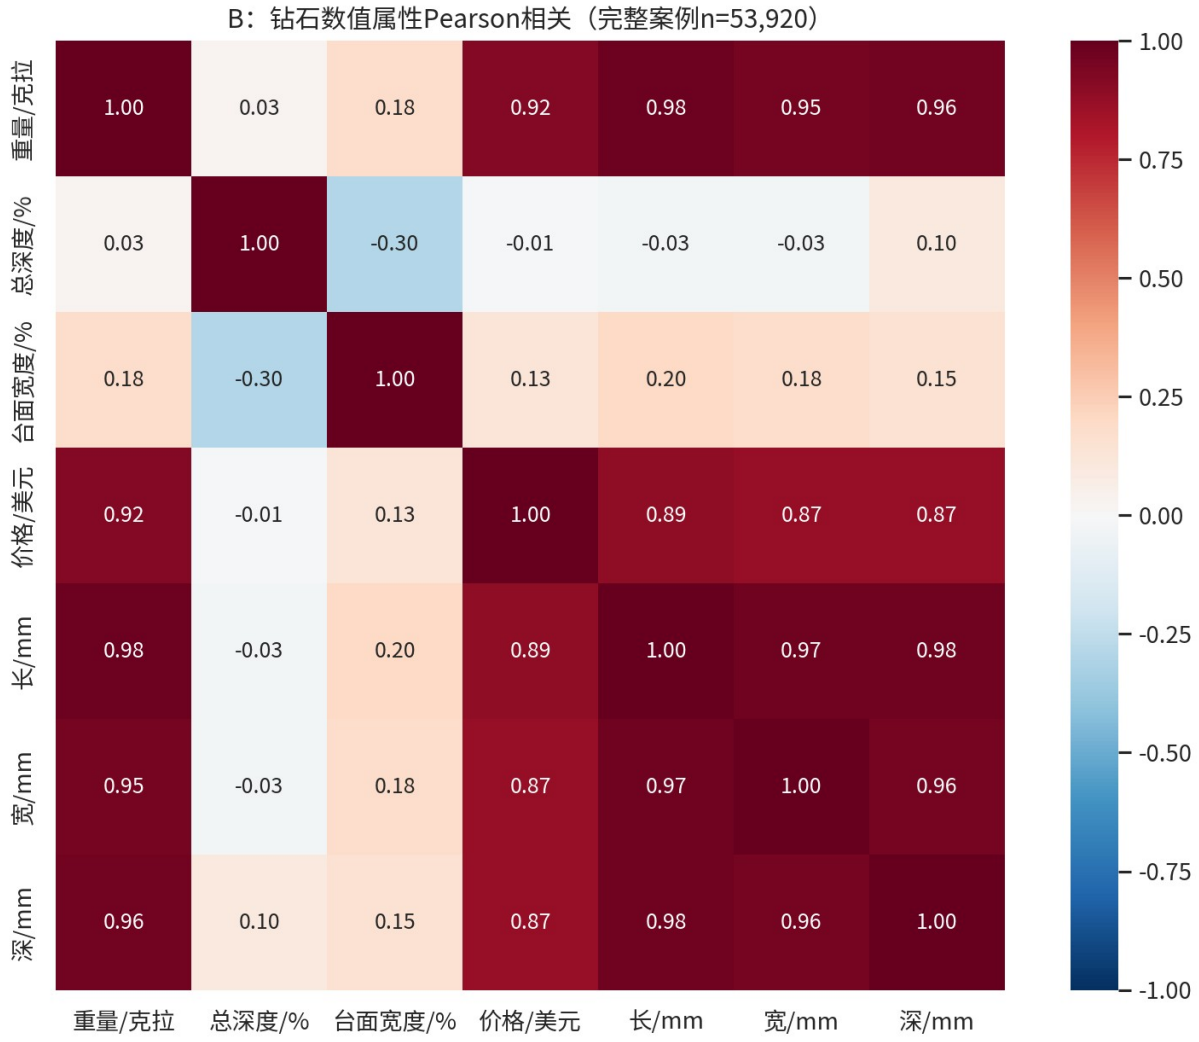


图 2 钻石属性 Pearson 相关热力图

统一使用 53,920 个完整案例，颜色固定在−1 至 1。重量与价格相关系数为 0.922。类别变量未任意编码求 Pearson 相关；尺寸共线性、商品品质和极端值均会影响关系，不能从相关推出因果。

表 10 切工类别记录数与累计占比

cut	记录数	占比%	累计占比%
Ideal	21551	39.954	39.954
Premium	13791	25.567	65.521
Very Good	12082	22.399	87.920
Good	4906	9.095	97.015
Fair	1610	2.985	100

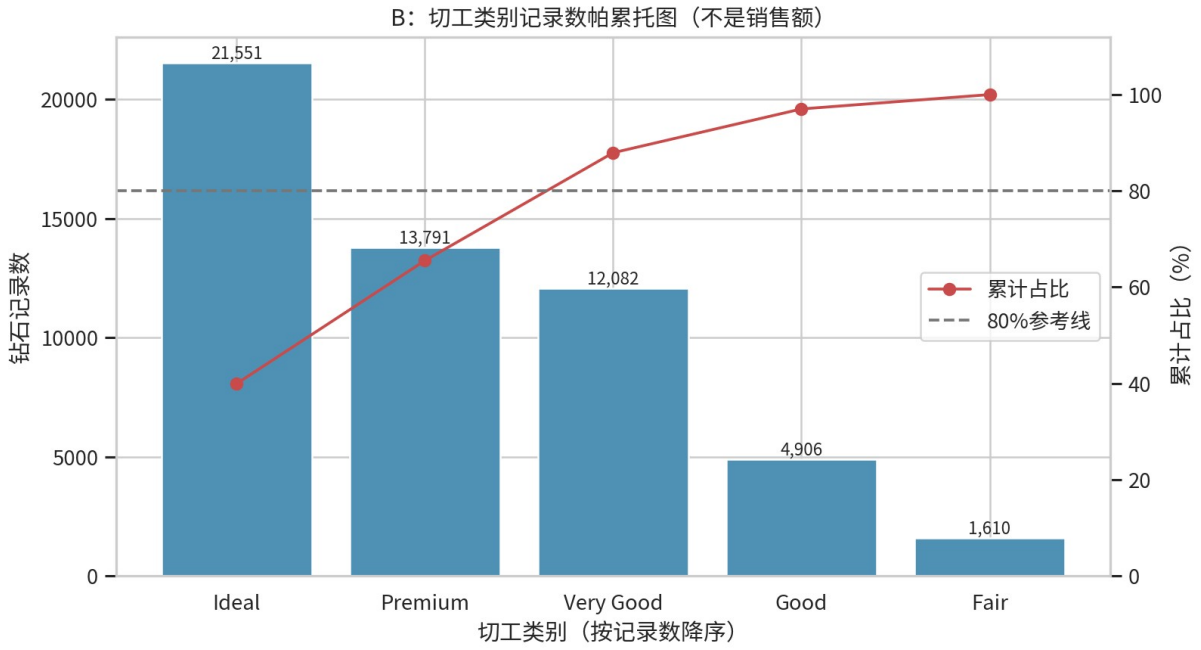


图 3 切工类别记录数帕累托图

柱形按记录数降序，折线为累计记录数除以 53,940，末点为 100%；横线为 80%参考。前 3 类约占 87.9%，不是预设的二八定律。记录占比不等于销量、收入或市场份额。

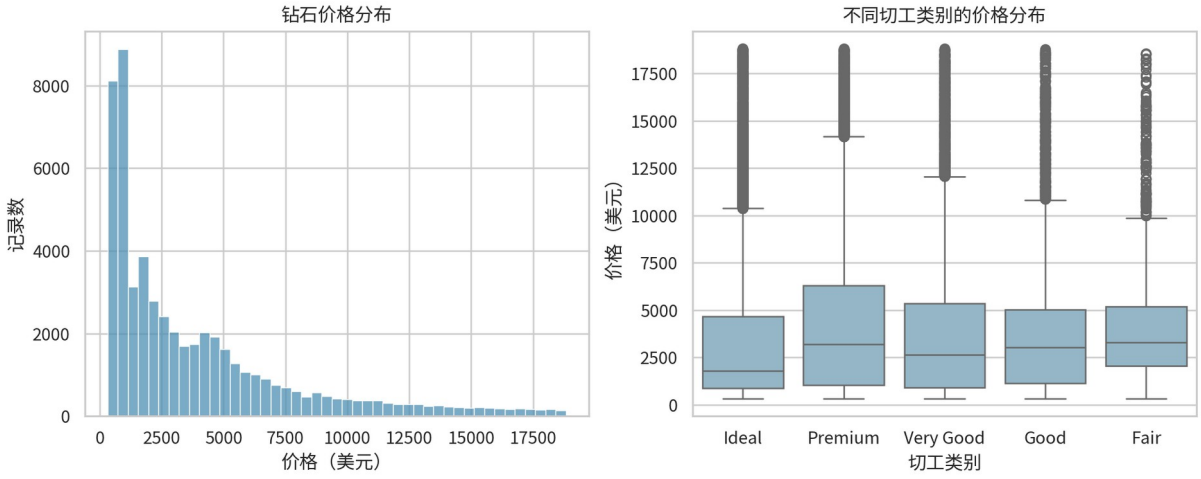


图 4 价格分布及不同切工的箱线图

价格均值 3932.80 美元高于中位数 2401 美元，呈右偏。不同切工的价格同时受重量、颜色和净度构成影响，不能只凭箱线图断言切工的独立价格效应。

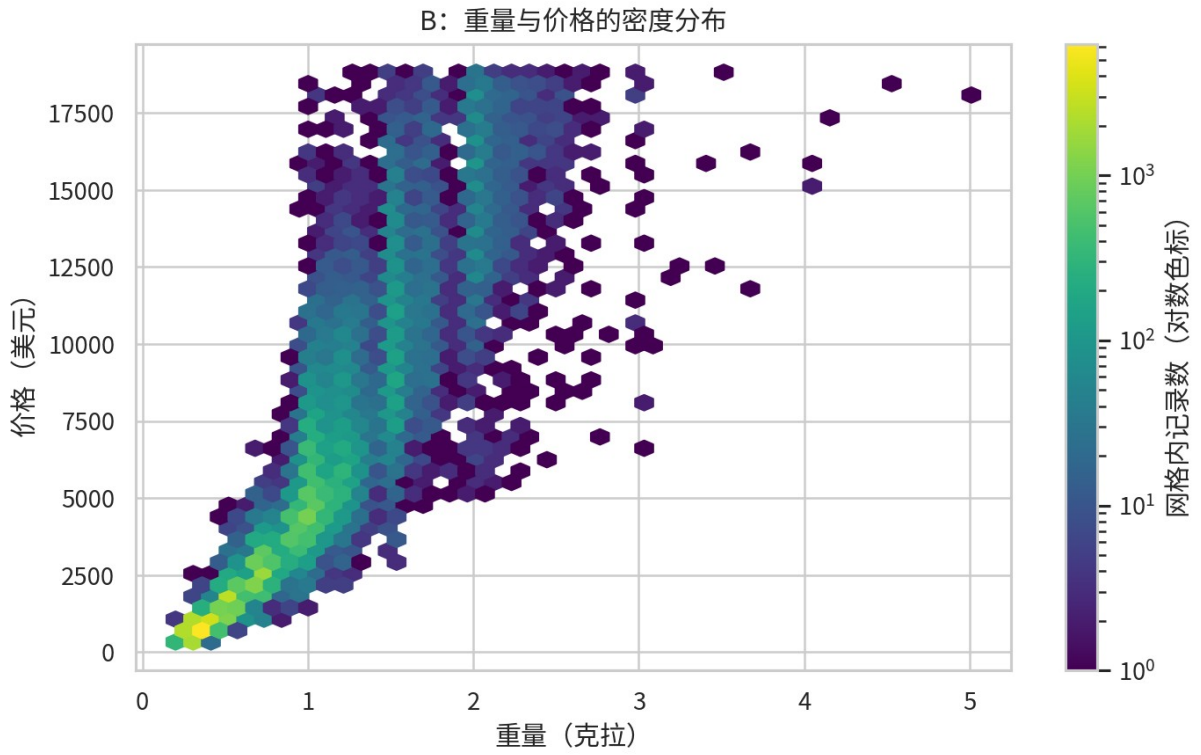


图 5 重量—价格密度图

六边形网格汇总密集观测，色标使用对数以缓解重叠。总体随重量上升的价格趋势明显，但同重量仍有较大价格差异，单个相关系数不能表达全部结构。

B6 约 200 字分析结论

本次探索 53,940 条真实钻石价格记录，原始表无缺失；20 条记录含零尺寸，已改记缺失。146 条完全重复候选因无商品编号而保留。价格中位数为 2401 美元，均值为 3933 美元，呈右偏。完整案例中重量与价格相关系数为 0.922。IQR 标记价格候选 3540 条，但高价不等于错误。切工前 3 类累计占 87.9%。样本类别占比不是市场份额，相关不能证明因果。数据为价格横截面，缺少成交量和抽样框，不能推断整体零售市场。

结论共 201 个字符（含数字与标点）。局限：样本无完整抽样框和订单粒度，价格随市场时期变化；零尺寸、可疑极端尺寸、重复候选的未核实部分，以及完整案例选择均可能影响结果。

C 挑战题：Kaggle Titanic 探索

C1 题目要求、数据来源与基本信息

使用带 Survived 标签的经典训练集，研究性别、年龄、舱位与生存率、年龄及船舱号缺失模式，以及分舱位票价分布；仅做 EDA，不训练模型、不计算预测准确率。

官方入口：https://www.kaggle.com/competitions/titanic/data

可信公开教学镜像：https://raw.githubusercontent.com/ageron/handson-ml2/master/datasets/titanic/train.csv

复用环境中已保存的镜像 CSV，核验 891 行、12 列、PassengerId 唯一、Survived 为 0 或 1、Pclass 为 1 至 3；未声称与需登录的 Kaggle 原始下载进行了逐字节校验。Pclass 为舱位等级，Cabin 为具体船舱号；二者不可混为一谈。SibSp 为同船兄弟姐妹/配偶数，Parch 为父母/子女数。

表 11 字段类型与非空数量

字段	类型	非空数
PassengerId	int64	891
Survived	int64	891
Pclass	int64	891
Name	object	891
Sex	object	891
Age	float64	714
SibSp	int64	891
Parch	int64	891
Ticket	object	891
Fare	float64	891
Cabin	object	204
Embarked	object	889

表 12 前五行（转置显示，保留原始字段值）

index	第 1 行	第 2 行	第 3 行	第 4 行	第 5 行
PassengerId	1	2	3	4	5
Survived	0	1	1	1	0
Pclass	3	1	3	1	3
Name	Braund, Mr. Owen Harris	Cumings, Mrs. John Bradley (Florence Briggs Thayer)	Heikkinen, Miss. Laina	Futrelle, Mrs. Jacques Heath (Lily May Peel)	Allen, Mr. William Henry
Sex	male	female	female	female	male
Age	22	38	26	35	35
SibSp	1	1	0	1	0
Parch	0	0	0	0	0
Ticket	A/5 21171	PC 17599	STON/O2. 3101282	113803	373450

index	第 1 行	第 2 行	第 3 行	第 4 行	第 5 行
Fare	7.250	71.283	7.925	53.100	8.050
Cabin	—	C85	—	C123	—
Embarked	S	C	S	S	S

表 13 年龄、票价与亲属数量描述统计

index	count	mean	std	min	25%	50%	75%	max
Age	714	29.699	14.527	0.417	20.125	28	38	80
Fare	891	32.204	49.693	0	7.910	14.454	31	512.329
SibSp	891	0.523	1.103	0	0	0	1	8
Parch	891	0.382	0.806	0	0	0	0	6

PassengerId 是身份标识，不解释其均值；Pclass 和 Survived 按分类/二元标签解释。完整数值及类别描述统计见 CSV。完全重复记录数为 0。

C2 缺失处理与关键代码

表 14 全部字段缺失数量和比例

字段/分组	缺失数	缺失率%
PassengerId	0	0
Survived	0	0
Pclass	0	0
Name	0	0
Sex	0	0
Age	177	19.865
SibSp	0	0
Parch	0	0
Ticket	0	0
Fare	0	0
Cabin	687	77.104
Embarked	2	0.224

Age 缺失 177 条，Cabin 缺失 687 条，Embarked 缺失 2 条。年龄图与分组仅用 714 个已知年龄，缺失组另列；不以均值年龄填补，不猜测船舱号。登船港不参与本次重点分析，保留缺失。分组比例的分母均为本组人数。

```
def 生存汇总(frame, by):
    result = frame.groupby(by, observed=True)['Survived'].agg(样本数='size', 生存人数='sum', 生存率='mean')
    result['死亡人数'] = result['样本数'] - result['生存人数']
    result['生存率%'] = result['生存率'] * 100
    return result[['样本数', '生存人数', '死亡人数', '生存率', '生存率%']]


labels = ['0—11 岁', '12—17 岁', '18—34 岁', '35—59 岁', '60 岁及以上']
eda['年龄组'] = pd.cut(eda.Age, bins=[0, 12, 18, 35, 60, np.inf], labels=labels, right=False)
age = 生存汇总(eda.dropna(subset=['Age']), '年龄组')
```

C3 总体、性别与舱位生存情况

表 15 总体生存情况

字段/分组	样本数	生存人数	死亡人数	生存率	生存率%
全体	891	342	549	0.384	38.384

表 16 不同性别的生存人数、死亡人数和比率

Sex	样本数	生存人数	死亡人数	生存率	生存率%
female	314	233	81	0.742	74.204
male	577	109	468	0.189	18.891

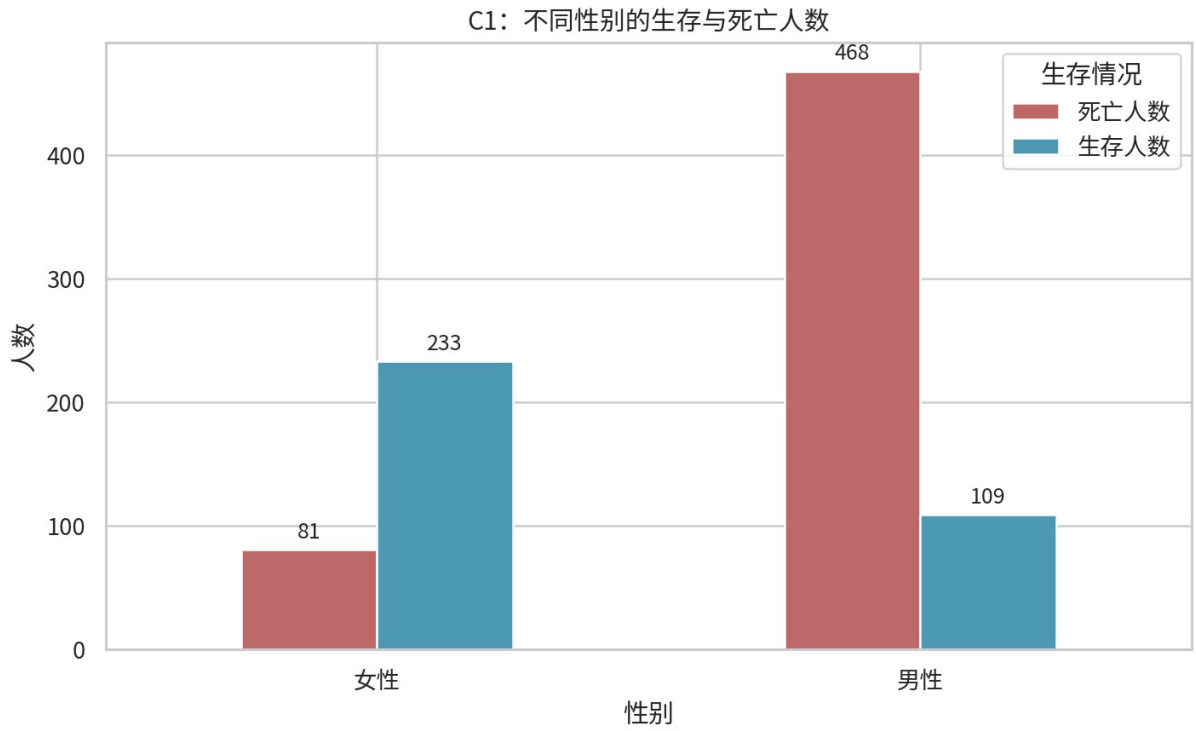


图 6 不同性别的生存与死亡人数

女性生存率 74.20%，男性 18.89%。图中柱高是人数，性别样本量不同，比较生存倾向应同时查看表中的组内比例。

表 17 不同舱位的样本量与生存率

Pclass	样本数	生存人数	死亡人数	生存率	生存率%
1	216	136	80	0.630	62.963
2	184	87	97	0.473	47.283
3	491	119	372	0.242	24.236

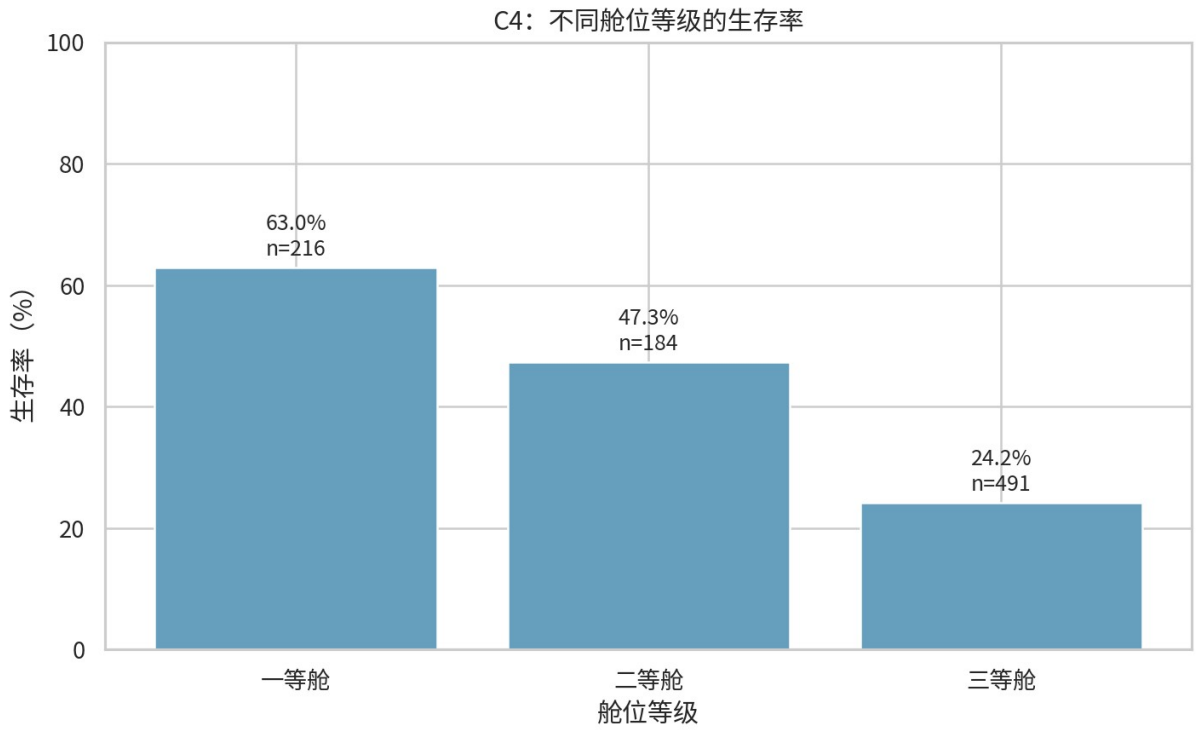


图 7 不同舱位等级的生存率

一等舱 62.96%、二等舱 47.28%、三等舱 24.24%。三等舱人数最多，而生存率最低；这反映样本关联，不等同于只由票价或舱位单独造成的因果效应。

表 18 性别×舱位的分层对照

Pclass	Sex	样本数	生存人数	死亡人数	生存率	生存率%
1	female	94	91	3	0.968	96.809
1	male	122	45	77	0.369	36.885
2	female	76	70	6	0.921	92.105
2	male	108	17	91	0.157	15.741
3	female	144	72	72	0.500	50
3	male	347	47	300	0.135	13.545

各舱位中女性的生存率均高于男性，分层对照支持差异并非只来自总体舱位构成；仍可能存在年龄、救援顺序等其他混杂。

C4 年龄分布与年龄组生存率

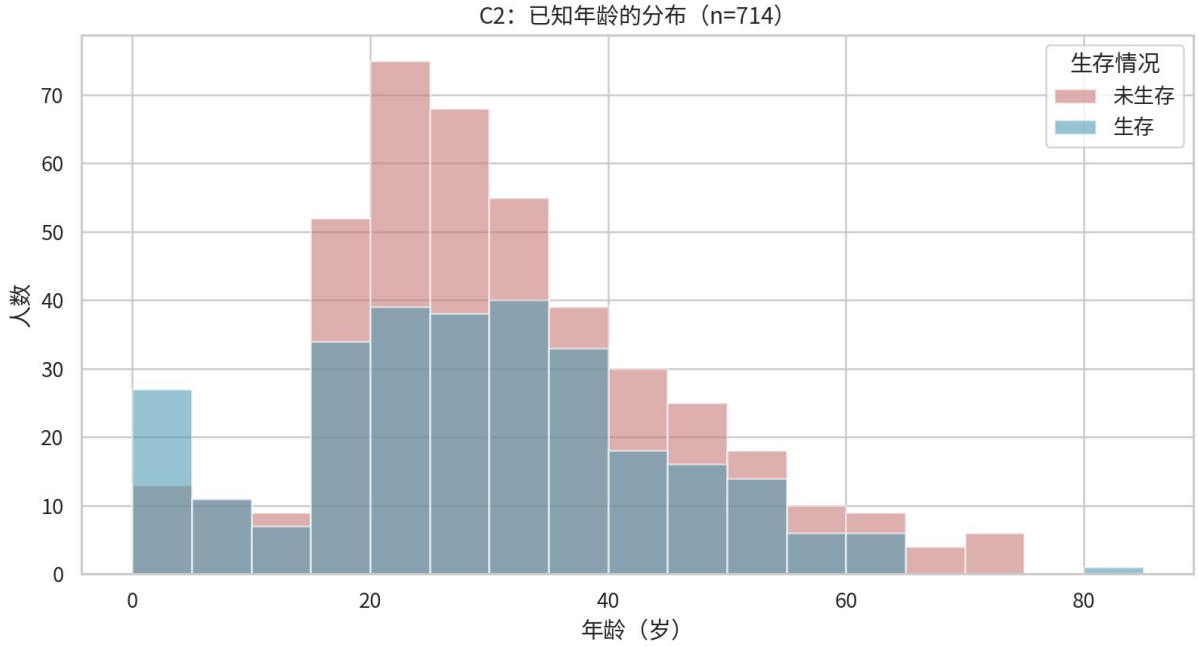


图 8 按生存情况展示年龄分布

仅展示已知年龄者，5 岁一个区间，两组直方图透明叠加。高度是人数而非概率；年龄缺失者未被塞入任何年龄段。

表 19 已知年龄分组（区间左闭右开）

年龄组	样本数	生存人数	死亡人数	生存率	生存率%
0—11 岁	68	39	29	0.574	57.353
12—17 岁	45	22	23	0.489	48.889
18—34 岁	366	135	231	0.369	36.885
35—59 岁	209	87	122	0.416	41.627
60 岁及以上	26	7	19	0.269	26.923

表 20 年龄缺失者单独汇总

字段/分组	样本数	生存人数	死亡人数	生存率	生存率%
年龄缺失	177	52	125	0.294	29.379

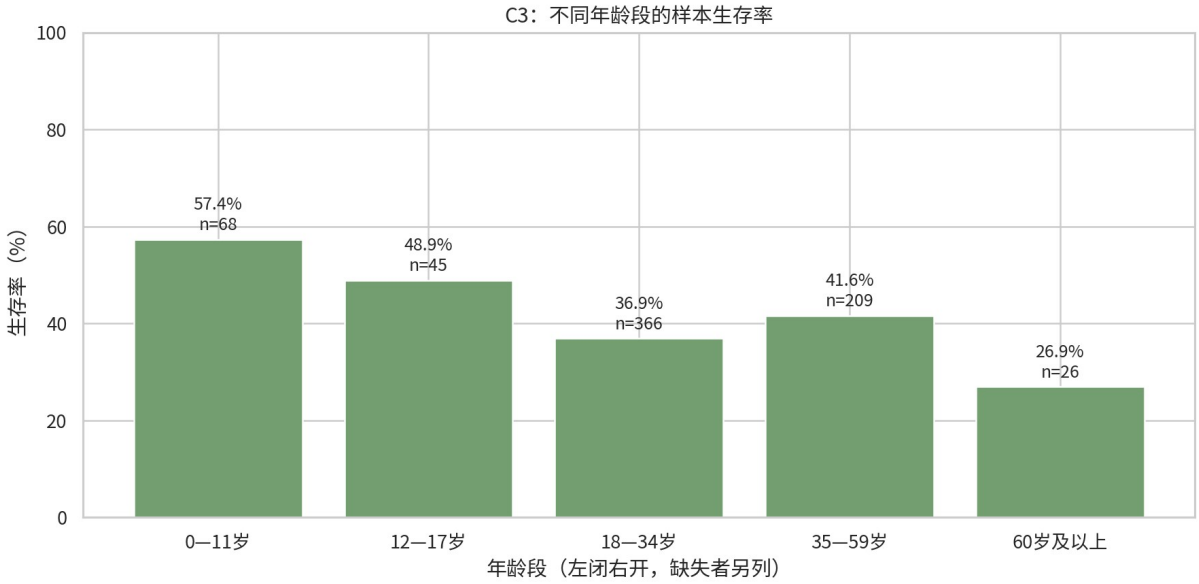


图 9 不同年龄组的生存率

0—11 岁组具有较高生存率，但各年龄段并非严格单调下降。每根柱标出分母，小年龄组比率波动更大；分组边界改变也会改变结果，不应将其当作每增加一岁的独立效应。

C5 Age 与 Cabin 缺失分布

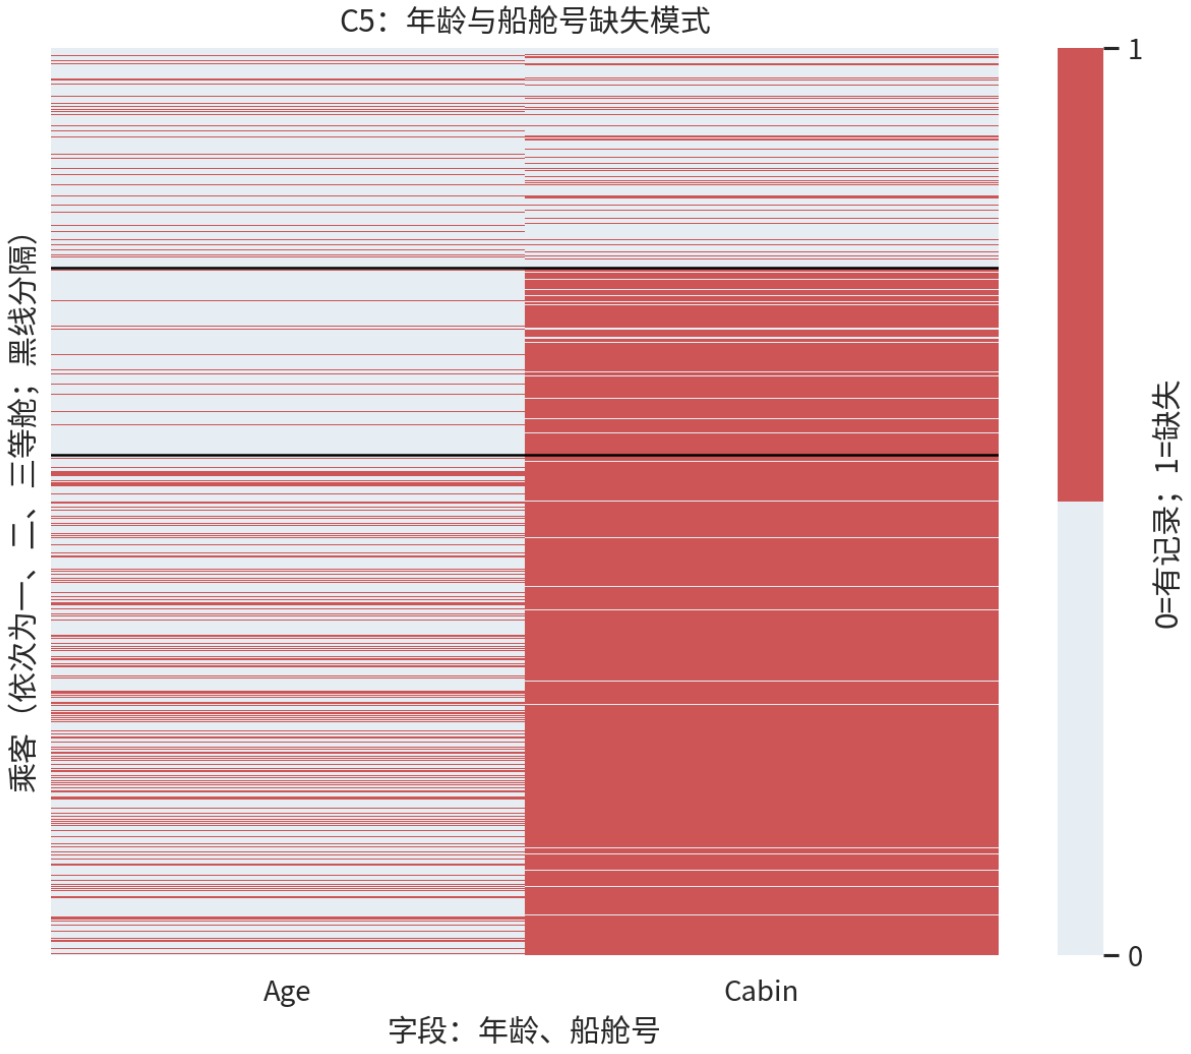


图 10 年龄与船舱号缺失矩阵

乘客按舱位排序，黑线分隔三组。红色表示缺失而非数值较大；船舱号缺失在三等舱更集中。

表 21 按舱位的缺失率（%）

Pclass	样本数	年龄缺失	船舱号缺失
1	216	13.889	18.519
2	184	5.978	91.304
3	491	27.699	97.556

表 22 按生存状态的缺失率（%）

Survived	样本数	年龄缺失	船舱号缺失
0	549	22.769	87.614
1	342	15.205	60.234

表 23 按性别的缺失率（%）

Sex	样本数	年龄缺失	船舱号缺失
female	314	16.879	69.108
male	577	21.490	81.456

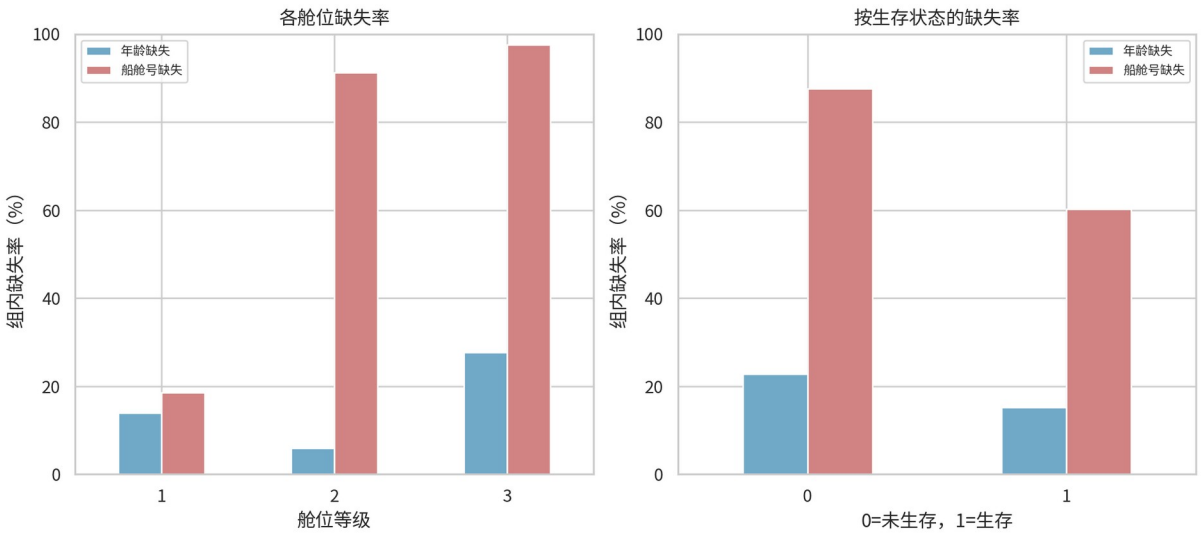


图 11 缺失率与舱位、生存状态关联

图表显示 Cabin 缺失与舱位和生存状态有关。由于舱位与生存状态也相关，不能把每个差异独立解释；仅凭这些表无法证明 MAR 或 MNAR 等完整缺失机制。

C6 分舱位票价箱线图

表 24 分舱位票价描述统计

Pclass	count	mean	std	min	25%	50%	75%	max
1	216	84.155	78.380	0	30.924	60.288	93.500	512.329
2	184	20.662	13.417	0	13	14.250	26	73.500
3	491	13.676	11.778	0	7.750	8.050	15.500	69.550

表 25 分舱位原始票价 IQR 候选与零票价

舱位	下界	上界	异常候选数	零票价人数
1	-62.940	187.364	20	5
2	-6.500	45.500	7	6
3	-3.875	27.125	52	4

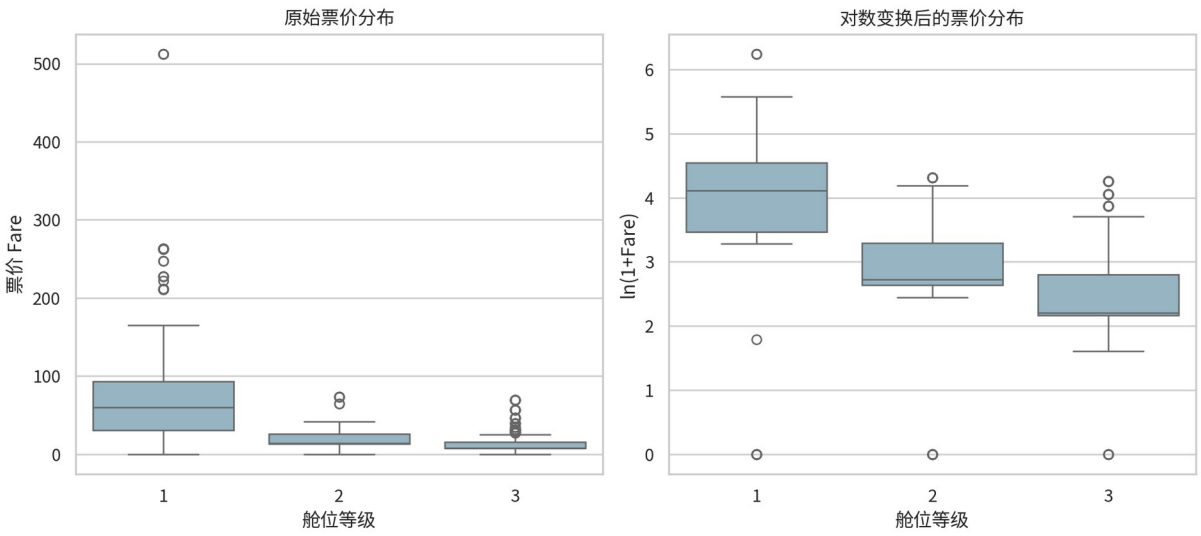


图 12 不同舱位的票价箱线图

票价右偏，高价可能代表多人共同购票或不同舱位服务，不能直接当成错误。本次按舱位在原始尺度上标记 79 条候选，15 条零票价另列。log1p 允许保留零值并观察中心分布；右图的箱线边界在变换尺度计算，不能与左图候选逐点等同。

C7 从数据中可以看出的规律

本分析使用 891 名乘客、12 个字段的经典训练集，342 人生存、549 人死亡，总体生存率为 38.38%。未进行模型训练。

女性生存率 74.20%，男性为 18.89%；一、二、三等舱分别为 62.96%、47.28%、24.24%。性别与舱位交叉表显示，各舱位女性生存率均高于同舱男性。上述差异是样本关联，不能直接解释为单一因素的因果效果。

年龄已知 714 人、缺失 177 人；仅已知年龄者参与年龄图和分组，缺失者单列，生存率为 29.38%。0—11 岁组 68 人、生存率 57.35%；60 岁及以上组 26 人、生存率 26.92%。年龄组生存率并非严格单调；分组边界和小样本会影响比较。直方图展示人数，不能仅凭柱高推断条件生存率。

Cabin 缺失 687 条（77.10%）。一等舱船舱号缺失率为 18.52%，三等舱为 97.56%；未生存组为 87.61%，生存组为 60.23%。缺失与已观察到的舱位和生存状态存在关联，不宜直接假设完全随机缺失；仅凭 EDA 不能判定完整的缺失机制。

分舱位 IQR 标记 79 条票价候选，另有 15 条零票价。高票价可能与舱位、多人共票等有关，零票价也需回查背景，均保留。原始与 log1p 箱线图分别展示金额和中心区域；变换尺度的 IQR 候选不必与原始尺度一致。

结论限于该训练样本。年龄缺失和完整案例筛选可能引入偏差；小年龄组比例更不稳定。该训练集不是全部乘客普查，舱位、性别、年龄与救援安排相互关联，不应将描述性差异推广为总体因果结论。

D 思维题：你是数据侦探

D1 题目、方法与优先级

仅给出用户 ID、下单时间、商品类别、金额、是否退货五个字段，没有提供实际交易数据。以下 12 项均为潜在问题及处理建议，不声称发现了真实问题。本题无需编造数据或运行统计程序。P0 先确认关键结构与口径，P1 核查数值和跨字段逻辑，P2 检查观察窗口与覆盖范围。

表 26 电商潜在数据质量问题、影响、检测与处理

优先级／问题	可能的异常现象	对分析的影响	检测方法	建议处理方案
P0／1. 重复记录	同一订单被重复导出；也可能两笔真实交易恰好五字段相同	销售额、订单数和退货率分母可能重复计算	查完全重复行；申请订单 ID、订单明细 ID，与源系统核对	只删除已确认的重复上报并记录数量；仅有五字段无法可靠判重，不能机械删重
P0／2. 关键字段缺失	用户 ID、时间、类别、金额或退货状态为空	无法关联用户、按时间汇总或正确计算金额和退货率	按列统计缺失数、缺失率，并按时间和来源分组检查	优先回源补全；关键缺失隔离，类别可标未知；未知金额不填 0，未知退货状态不当作未退货
P0／3. 用户 ID 与字段类型错误	ID 前导零丢失，时间和金额仍是杂乱字符串	用户合并错误；排序、求和、筛选失真	核对字段模式、唯一值、长度和数据类型；解析失败单列	ID 按字符串读取；按明确格式转换字段并保留原值；无法恢复的 ID 应回源，不凭空补零
P0／4. 金额单位或币种不一致	元与分混用，人民币和美元混列，含千位分隔符	销售额可能相差百倍；跨币种求和没有意义	核对金额元数据、符号、来源系统与数量级	按源口径统一单位；若换汇，记录交易日汇率和基准币种；缺乏币种依据则隔离，不能猜测
P1／5. 非法或含义不明金额	普通销售为负值、无穷值、零值，或字符串无法转换	影响营业额、客单价与分布	数值解析、有限性与业务范围检查；交叉核对交易类型	核查退款、赠品和优惠；有凭据才更正，合法零金额保留，无法解释的记录标记隔离

优先级／问题	可能的异常现象	对分析的影响	检测方法	建议处理方案
P1／6. 异常大额订单	金额远高于同类别常见值	均值被极端值拉高，也可能是真实大客户	分商品类别或时间段做 IQR 筛查，结合数量、订单和支付凭据复核	异常候选不等于错误；真实大额保留并单独说明，确认录入错误才修正，不无依据截尾
P1／7. 时间异常	无效日期、未来时间、时区混杂，批量落在默认日期	日销量、节假日效应和先后关系判断失真	用明确格式解析，失败设 NaT；核对时区、业务上线日和提取截止日	统一时区与格式，回源修正；无法恢复则标记，不替换成当前时间；保留原始时间
P1／8. 商品类别不规范	手机、手机类、前后空格混用，父类子类混列	同类被拆散，帕累托图和类别比较失真	统计唯一值和频数，与商品分类字典比对	去除无意义空格，按经过审核的映射统一；未知类别单列，保留原类别与映射版本
P1／9. 退货标签不一致	是/否、Y/N、0/1 混用；空值或处理中被记为否	退货率偏低或高估，状态失去可比性	查看所有标签，与订单状态及退款流水做交叉核对	明确已退货、未退货、处理中、未知的定义；建立映射，保留未知，不简单全部转成 0
P1／10. 跨字段逻辑矛盾	退货早于购买；已退货却无退款；负金额与销售口径冲突	净销售额和退货归属月份错误	补充订单 ID、退货时间、退款金额和状态历史，校验顺序与金额关系	先确认字段代表购买额还是退款额；区分部分退款、换货等情形，隔离冲突记录交业务复核
P2／11. 退货观察窗口不足	新订单还没过退货期，却与老订单一起算退货率	新订单退货率被系统性低估	按下单日计算可观察时长，核对数据截止日及退货窗口	比较窗口已结束的订单，或将未成熟订单单列；报告截止日、观察窗口与分母
P2／12. 覆盖范围和关联完整性	漏导某些日期或渠道，用户不在主表，取消订单混入销售	样本不能代表业务全貌，汇总无法与财务核对	对账每日记录数和金额，核查时间覆盖与外键，检查订单状态	回源补齐、标记缺口；定义纳入与排除规则，并披露剩余覆盖偏差

D2 推荐检查顺序和结论

1. 明确数据粒度（订单还是订单明细）、金额含义、时区、退货定义和观察截止日。

2. 保存原始快照，检查字段是否齐全，申请必要的订单主键和状态信息。

3. 检查关键缺失、类型、重复候选、币种与单位；记录每步前后样本数。

4. 检查时间、金额、类别、退货标签及跨字段逻辑；将待核实记录分开保存。

5. 分组检测异常，核查观察窗口和数据覆盖；输出质量报告并与源系统对账。

数据清洗的目标是让口径清楚、过程可追溯、统计结论可信，而不是让所有值都显得整齐。应区分真实极端交易与录入错误，避免把未知当作零或正常。对关键指标建立持续监测、责任人和规则版本，才能让销售额、客单价与退货率在不同时间和业务部门之间保持可比较性。

附录：来源、复现与验收

数据与字体来源

B：diamonds：53,940 颗钻石价格与属性；地址：https://raw.githubusercontent.com/mwaskom/seaborn-data/master/diamonds.csv

文件：B_真实数据 EDA/原始数据.csv；SHA-256：9574730b03aba241d899c4a97511c5061b19358fab89510774fb6c24168345c4

C：Kaggle Titanic 经典训练集公开教学镜像；地址：https://raw.githubusercontent.com/ageron/handson-ml2/master/datasets/titanic/train.csv

文件：C_Titanic 数据探索/train.csv；SHA-256：14769fb1850e2d26d8e6db0ee49c213878040432827e39b13caaa15603c6598f

字体：Noto Sans CJK SC；地址：https://github.com/notofonts/noto-cjk

文件：资源/NotoSansCJKsc-Regular.otf；SHA-256：2c76254f6fc379fddfce0a7e84fb5385bb135d3e399294f6eeb6680d0365b74b

文件摘要用于确认当前文件版本和复现一致性，并非数据真实性的独立证明。字体许可随资源目录提供。Word 引用 Noto Sans CJK SC 字体；若本机未安装可使用随附字体，图表中文已作为像素写入 PNG。

复现步骤与文件对应

在项目目录安装 requirements.txt 后，依次运行 A_异常值检测/A_异常值检测.py、B_真实数据 EDA/B_数据探索.py、C_Titanic 数据探索/C_Titanic 数据探索.py，再运行生成 Word 报告.py。也可执行一键运行.py。脚本以自身位置定位数据，从其他工作目录启动也可运行。原始 B/C 数据不被改写；重复运行会刷新统计表、图表与报告。

A：模拟数据、真实注入异常、全部检测结果、混淆矩阵及箱线图。B：原始/清洗数据、缺失与异常记录、描述统计、相关系数、帕累托统计及 4 张图。C：原始训练集、分组人数/死亡/生存率、所有字段缺失、交叉统计、票价候选及 7 张图。D：12 类问题及优先级完整 Markdown 答案。

验收包含程序退出状态、数据规模、A 题真值对照、数据来源摘要、Pareto 累计 100%、Titanic 分组人数守恒、12 张图片可解码且尺寸有效，以及 Word 文档内容和图片数量。完整检查由验证成果.py 实际执行，输出验证结果.json。